

#### МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

## «МИРЭА – Российский технологический университет» РТУ МИРЭА

Кафедра: КБ-4 «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта»

# Практическая работа №4 по дисциплине «Анализ защищенности систем искусственного интеллекта»

Выполнил: Филимонов И.М. Группа: ББМО-01-22, 2 курс

Проверил: Спирин А.А.

#### 1. Установить пакет art.

#### 2. Загружаем необходимые библиотеки.

```
[2] from __future__ import absolute_import, division, print_function, unicode_literals
12
        import os, svs
        from os.path import abspath
        module_path = os.path.abspath(os.path.join('...'))
        if module_path not in sys.path:
          sys.path.append(module_path)
        import warnings
        warnings.filterwarnings('ignore')
        import tensorflow as tf
        tf.compat.v1.disable_eager_execution()
        tf.get_logger().setLevel('ERROR')
        import tensorflow.keras.backend as k
        from tensorflow.keras.models import Sequential
        from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
        import numpy as no
        import matplotlib.pyplot as plt
        %matplotlib inline
        from art.estimators.classification import KerasClassifier
        from art.attacks.poisoning import PoisoningAttackBackdoor, PoisoningAttackCleanLabelBackdoor
        from art.attacks.poisoning.perturbations import add_pattern_bd
        from art.utils import load_mnist, preprocess, to_categorical
        from art.defences.trainer import AdversarialTrainerMadryPGD
```

#### 3. Загружаем датасет MNIST.

```
[3] # Загружаем датасет MNIST
(x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

# Случайная выборка:
n_train = np.shape(x_raw)[0]
num_selection = 10000
random_selection_indices = np.random.choice(n_train, num_selection)
x_raw = x_raw[random_selection_indices]
y_raw = y_raw[random_selection_indices]
```

### 4. Выполняем отравление данных.

```
[4] # Отравленные данные

percent_poison = .33

x_train, y_train = preprocess(x_raw, y_raw)

x_train = np.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)

x_test = np.expand_dims(x_test, axis=3)

# Перемешать данные обучения

n_train = np.shape(y_train)[0]

shuffled_indices = np.arange(n_train)

np.random.shuffle(shuffled_indices)

x_train = x_train[shuffled_indices]

y_train = y_train[shuffled_indices]
```

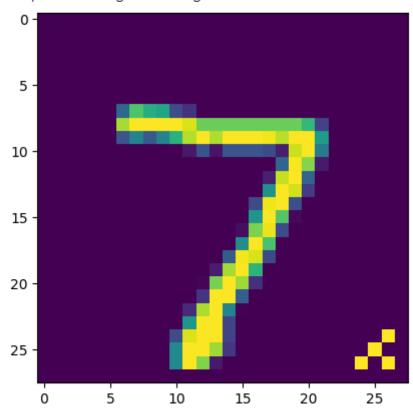
5. Написание функции «create\_model()» для создания последовательной модели из 9 слоев.

```
[5] # Функция create_model() для создания последовательной модели из 9 слоев
     from tensorflow.keras.models import Sequential
     from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Dropout
     def create_model():
         # Архитектура модели
         model = Sequential()
         # Сверточные слои
         model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
         model.add(Conv2D(64, (3, 3), activation='relu'))
         # Пулинговый слой
         model.add(MaxPooling2D(pool_size=(2, 2)))
         # Dropout слой
         model.add(Dropout(0.25))
         # Выравнивающий слой
         model.add(Flatten())
         # Полносвязные слои
         model.add(Dense(128, activation='relu'))
         model.add(Dropout(0.25))
         model.add(Dense(10, activation='softmax'))
         model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
         return model
```

#### 6. Создаем атаку.

```
[6] # Создаем атаку
backdoor = PoisoningAttackBackdoor(add_pattern_bd)
example_target = np.array([0, 0, 0, 0, 0, 0, 0, 0, 1])
pdata, plabels = backdoor.poison(x_test, y=example_target)
plt.imshow(pdata[0].squeeze())
```

<matplotlib.image.AxesImage at 0x7962397226e0>



#### 7. Определяем целевой класс атаки.

```
(7) # Определяем целевой класс атаки targets = to_categorical([9], 10)[0]
```

#### 8. Создаем модель.

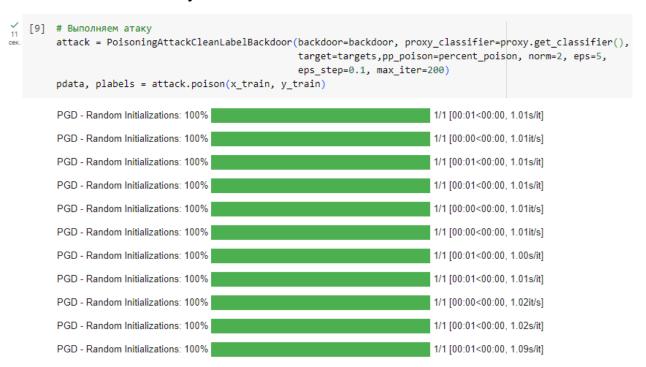
```
# Создаем модель
model = KerasClassifier(create_model())
proxy = AdversarialTrainerMadryPGD(KerasClassifier(create_model()),
nb_epochs=10, eps=0.15, eps_step=0.001)
proxy.fit(x_train, y_train)

Precompute adv samples: 100%

Adversarial training epochs: 100%

10/10 [02:17<00:00, 12:34s/it]
```

#### 9. Выполняем атаку.

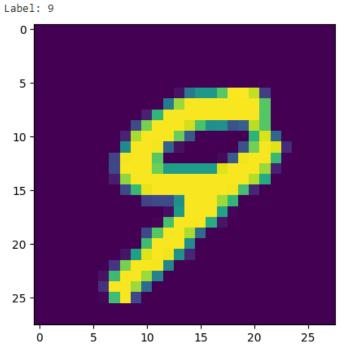


#### 10. Создаем отравленные примеры данных.

```
[10] # Создаем отравленные примеры данных poisoned = pdata[np.all(plabels == targets, axis=1)] poisoned_labels = plabels[np.all(plabels == targets, axis=1)] print(len(poisoned))

idx = 0 plt.imshow(poisoned[idx].squeeze()) print(f"Label: {np.argmax(poisoned_labels[idx])}")

976
```



#### 11. Обучаем модель на отравленных данных.

```
[11] # Обучаем модель на отравленных данных model.fit(pdata, plabels, nb_epochs=10)
```

#### 12. Осуществляем тест на чистых данных.

```
[12] # Осуществляем тест на чистой модели

clean_preds = np.argmax(model.predict(x_test), axis=1)

clean_correct = np.sum(clean_preds == np.argmax(y_test, axis=1))

clean_total = y_test.shape[0]

clean_acc = clean_correct / clean_total

print("\nClean test set accuracy: %.2f%" % (clean_acc * 100))

# Как отравленная модель классифицирует чистый образец

c = 0 # Класс для отображения

i = 0 # Изображение класса для отображения

c_idx = np.where(np.argmax(y_test, 1) == c)[0][i] # Индекс изображения в чистых массивах

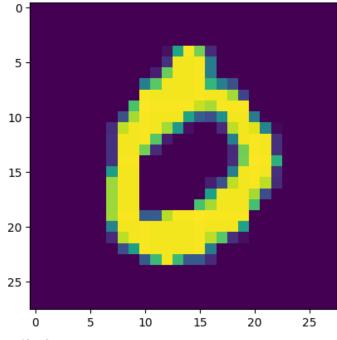
plt.imshow(x_test[c_idx].squeeze())

plt.show()

clean_label = c

print("Prediction: " + str(clean_preds[c_idx]))
```

Clean test set accuracy: 97.83%



Prediction: 0

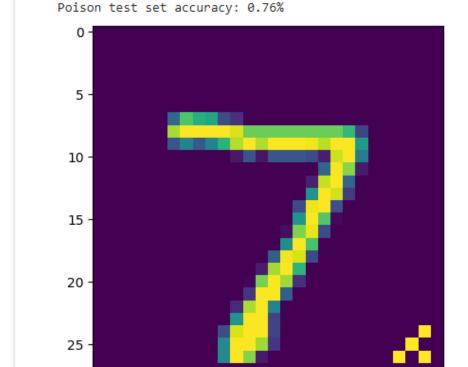
# 13. Осуществляем тест на отравленных данных и получаем результаты атаки на модель.

```
# Получаем результаты атаки на модель:
not_target = np.logical_not(np.all(y_test == targets, axis=1))
px_test, py_test = backdoor.poison(x_test[not_target], y_test[not_target]))
poison_preds = np.argmax(model.predict(px_test), axis=1))
poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target], axis=1)))
poison_total = poison_preds.shape[0]
poison_acc = poison_correct / poison_total

print("\nPoison test set accuracy: %.2f%%" % (poison_acc * 100))

c = 0 # Индекс для отображения
plt.imshow(px_test[c].squeeze())
plt.show()
clean_label = c

print("Prediction: " + str(poison_preds[c]))
```



10

15

20

5

Prediction: 9